

Projet #1

IFT-3225

9 mars 2025

Yanis Boulogne (20316250)
Karl-Antoine Plouffe (20218864)

1 Répartition des tâches

Yanis Boulogne	Karl-Antoine Plouffe
— Créer le module Python pour extraire les images, les vidéos et les svg — Créer le module Python pour générer la page web en intégrant les médias précédemment extraits	— Création du gabarit HTML — Implémentation de styles avec Bootstrap — Implémentation du scripting DOM avec JavaScript — Création des scripts "<i>wrapper</i>" — Tests d'exécution des commandes — Rédaction du rapport

2 Pages générées

- `./extract -p ./img1 -i -v "https://www.ableton.com/en/" | ./genere > page1.html`
`https://www.ableton.com/en/` Page abritée au DIRO : `page1.html`
- `./extract -p ./img2 -s "https://www.ville-dechy.fr/" | ./genere > page2.html`
`https://www.ville-dechy.fr/` Page abritée au DIRO : `page2.html`
- `./extract -p ./img3 -r .jpg -s "https://www.umontreal.ca/" | ./genere > page3.html`
`https://montreal.ca/calendrier-culturel` Page abritée au DIRO : `page3.html`

3 Langages et librairies utilisés

3.1 Langages

- JavaScript
- Python 3
- TCSH

3.2 Librairies

- Bootstrap 5.3.3
- BeautifulSoup 4
- sys
- os
- re
- requests
- io

4 Traitements particuliers

4.1 Images

Pour la sauvegarde d'image, nous partons de la racine de l'url (exemple : `https://monsite.fr/`), pour remonter au fur et à mesure en ajoutant les sous-dossiers présents dans l'url de base et on s'arrête quand on a trouvé l'image ou atteint l'url fourni par l'utilisateur. Cette vérification peut prendre relativement beaucoup de temps, mais elle permet de maximiser les chances de récupérer l'image.

4.2 Images externes

Il est possible de télécharger les images externes affichées sur une page web, c'est-à-dire les images hébergées sur une page autre que la page visée, mais affichées sur celle-ci. On a donc ajouté l'option `-u` pour éviter de télécharger ces images. Une extension est ajoutée à ces images si elle n'en n'ont pas déjà, un cas rare que nous avons rencontré lors de nos tests.

4.3 SVG

Il en existe 2 type :

- Les images `.svg`
- Les images "*inline*" entre balises `<svg>` directement intégrées dans le HTML

On a ajouté l'option `-s` pour les retirer de l'extraction du site. Des fonction ont été créées juste pour ce type d'image. Si c'est une image `.svg`, les fonctions dédiées font simplement appel à celles déjà existantes pour les autres types d'image. Si c'est un ajout *inline*, il y a deux possibilités :

- Extraire sans sauvegarder : on récupère le contenu entre les deux balises `<svg>` et lui donne un nom basé sur l'id si il existe sinon on l'appelle `inlinei`.

- Sauvegarder les inlines : on vérifie d’abord leur conformité avant de les transformer en .svg qui seront gérés par *genere* comme une image classique avec comme nom le même fonctionnement que si on ne les sauvegarde pas.

Du côté de *genere*, les images svg sont traitées comme les autres types d’image.

4.4 Gabarit

Nous tenons à mentionner l’utilisation d’un gabarit HTML pour simplifier la génération des pages avec la commande *genere* réalisée en Python. Nous avons jugé plus élégant de copier le gabarit, d’y insérer les ressources récoltées par *extract* et d’en générer une nouvelle page HTML plutôt que d’avoir le gabarit de la page entreposé dans une énorme chaîne de caractères. Cela nous évite d’avoir à importer une librairie additionnelle pour générer élégamment du code HTML avec Python.

4.5 Wrappers

Pour lancer avec aisance les commandes tel que demandé, nous avons ajouté des scripts *wrappers* TCSH qui lancent à leur tour les fichiers Python.

5 Exécution des commandes

Notez bien : il faut exécuter les commandes avec la version de Python du DIRO sur le serveur *ens* ! À moins d’être ajoutées au *PATH*, ce que nous assumons ne pas pouvoir faire au DIRO, les commandes doivent être lancées en spécifiant leur chemin dans un invite de commande TCSH (que nous utilisons pour accommoder l’opérateur *>!*) ou en spécifiant *tcsh* devant le chemin de la commande. Les commandes se trouvent aux endroits suivants :

- /www/ens/hiver/~plouffek/MidnightPillarPerceval/extract
- /www/ens/hiver/~plouffek/MidnightPillarPerceval/genere

ou

- /www/ens/hiver/~boulogny/MonkeyLimousineDrum/extract
- /www/ens/hiver/~boulogny/MonkeyLimousineDrum/genere

À cause des politiques *umask* en place au DIRO, il est possible qu’une page web générée au DIRO dans le cadre de ce projet ne soit pas immédiatement disponible publiquement. Il faudra donc faire usage de *chmod* pour en permettre la lecture (exemple : *chmod 644 page1.html*) si on veut pouvoir la consulter avec un navigateur web.

Toutes les dépendances à installer (Python, TCSH, BeautifulSoup, requests) sont déjà présentes au DIRO sur le serveur *ens* (donc après avoir lancé *ssh ens* si on se connecte à distance via ssh).